Написать генератор текста и обучить его на баснях Эзопа.

Данные

Будем использовать сборник басен Эзопа на английском языке, который можно найти здесь.

Скрипт для загрузки (поместить в .sh файл):

FILE=\$1

NAME=\$2

URL=http://www.gutenberg.org/cache/epub/\$FILE/pg\$FILE.txt

TARGET_DIR=./data/\$NAME/
mkdir \$TARGET_DIR
TXT_FILE=./data/\$NAME/data.txt
wget -N \$URL -O \$TXT_FILE

Подготовка данных

- 1. перевести все в нижний регистр
- 2. разделить рассказы между собой группой символов: |||||||||||
- 3. применить токенайзер

Модель

На pytorch имплементировать следующую архитектуру:

Layer (type)	Output	Shape	Param #
input_1 (InputLayer)	(None,	None)	0
embedding_1 (Embedding)	(None,	None, 100)	416900
lstm_1 (LSTM)	(None,	256)	365568
dense_1 (Dense)	(None,	4169)	1071433

Total params: 1,853,901 Trainable params: 1,853,901 Non-trainable params: 0

Обучить данную модель на наборе басен Эзопа

Написать скрипт инференса.

Пример задания на keras.

Требования:

- Репозиторий github/gitlab
- Мониторинг обучения: ClearML или Weights & Biases. Допустимо использование TensorBoard
- Поместите в README графики и ваши выводы по успешности обучения на их основе
- Проводить эксперименты вы можете в ноутбуках, но окончательный код обучения и инференса желательно оформить в .py файлах
- Неудавшиеся эксперименты так же будут засчитаны, главное указать выводы, почему эксперимент не удался, что и как нужно изменить